

# Методы машинного обучения. Выявление аномалий и робастное обучение

Воронцов Константин Вячеславович

[www.MachineLearning.ru/wiki?title=User:Vokov](http://www.MachineLearning.ru/wiki?title=User:Vokov)

вопросы к лектору: [k.vorontsov@iai.msu.ru](mailto:k.vorontsov@iai.msu.ru)

материалы курса:

[github.com/MSU-ML-COURSE/ML-COURSE-24-25](https://github.com/MSU-ML-COURSE/ML-COURSE-24-25)

орг.вопросы по курсу: [ml.cmc@mail.ru](mailto:ml.cmc@mail.ru)

- 1 **Выявление аномальных объектов**
  - Эвристики для оценивания аномальности объектов
  - Отсев выбросов в непараметрической регрессии
  - Систематизация подходов
- 2 **Теория робастного (помехоустойчивого) обучения**
  - Робастные функции потерь
  - Робастные агрегирующие функции
  - Методы итерационного взвешивания
- 3 **Задачи с аномальными или новыми классами**
  - Одноклассовая классификация
  - Обучение по выборке одного класса
  - Задачи с новыми или неизвестными классами

## Задачи выявления аномалий (Anomaly Detection)

### Выявление выбросов (Outlier Detection)

- ошибки в данных обучающего или тестового объекта
- неадекватность модели на некоторых объектах

### Выявление «новизны» (Novelty Detection)


- ничего подобного не было в обучающей выборке

### Примеры приложений

- обнаружение мошенничества (Fraud Detection)
- обнаружение вторжений (Intrusion Detection)
- обнаружение инсайдерской торговли на бирже
- обнаружение неполадок по показаниям датчиков
- медицинская диагностика (Medical Diagnosis)

## Метрические методы


Аномальность объекта — расстояние до его  $k$ -го ближайшего соседа: чем больше, тем меньше локальная плотность выборки




*M.M.Breunig, H.-P.Kriegel, R.T.Ng, J.Sander. Local outlier factor: identifying density-based local outliers. 2000*

## Случайный изолирующий лес (IsolationForest)

- Строится случайный лес деревьев
- Каждое ветвление: случайный признак и порог
- В каждом листе остаётся только один объект
- *Аномальность объекта* — средняя глубина листьев, в которые он попадает: чем меньше, тем более объект изолирован



глубина 12




глубина 4

Fei Tony Liu, Kai Ming Ting, Zhi-Hua Zhou. Isolation Forest. 2008

## Случайный изолирующий лес (IsolationForest)

- Строится случайный лес деревьев
- Каждое ветвление: случайный признак и порог
- В каждом листе остаётся только один объект
- *Аномальность объекта* — средняя глубина листьев, в которые он попадает: чем меньше, тем более объект изолирован



<https://dyakonov.org/2017/04/19/поиск-аномалий-anomaly-detection>

## Разделение смеси распределений с фоновой компонентой

Порождающая модель смеси распределений:

$$p(x) = w_0 \varphi_0(x) + \sum_{j=1}^k w_j \varphi(x, \theta_j), \quad \sum_{j=0}^k w_j = 1, \quad w_j \geq 0,$$

Варианты задания **фонового распределения**  $\varphi_0(x)$ :

- сферическое гауссовское с большой дисперсией
- радиальное с тяжёлым хвостом (Лапласа,  $t$ -Стьюдента)

**Задача** максимизации логарифма правдоподобия

$$L(w, \theta) = \ln \prod_{i=1}^{\ell} p(x_i) = \sum_{i=1}^{\ell} \ln \left( w_0 \varphi_0(x_i) + \sum_{j=1}^k w_j \varphi(x_i, \theta_j) \right) \rightarrow \max_{w, \theta}$$

*Аномальность объекта*  $x_i$  — вероятность  $p(j=0|x_i)$  того, что он является фоновым, оценивается на Е-шаге EM-алгоритма

## Робастные автокодировщики (Robust AutoEncoder)

Автокодировщик реконструирует  $\hat{x} = g(f(x))$  по исходным  $x$ :

$$\sum_{i=1}^{\ell} \|g(f(x_i, \alpha), \beta) - x_i\|^2 \rightarrow \min_{\alpha, \beta}$$

*Аномальность объекта* — неизвестный разреженный шум  $(\varepsilon_i)_{i=1}^{\ell}$

Реконструируются незашумлённые объекты  $\tilde{x}_i = x_i - \varepsilon_i$ :

$$\sum_{i=1}^{\ell} \|g(f(x_i, \alpha), \beta) - (x_i - \varepsilon_i)\|^2 + \lambda \sum_{i=1}^{\ell} \|\varepsilon_i\|_1 \rightarrow \min_{\alpha, \beta, \varepsilon}$$

**Пример.** Робастный метод главных компонент (Robust PCA):

$$\|F - GU^T - E\|^2 + \lambda \|E\|_1 \rightarrow \min_{G, U, E}$$

где  $GU^T$  — матрица низкого ранга,  $E$  — разреженная матрица

---

C.Zhou, R.C.Paffenroth. Anomaly detection with robust deep autoencoders. 2017.

E.J.Candès, X.Li, Y.Ma, J.Wright. Robust Principal Component Analysis. 2009.



## Напоминание. Непараметрическая регрессия

Модель регрессии — константа  $f(x, \alpha) = \alpha$  в окрестности  $x$ :

$$Q(\alpha; X^\ell) = \sum_{i=1}^{\ell} w_i(x) (\alpha - y_i)^2 \rightarrow \min_{\alpha \in \mathbb{R}};$$

где  $w_i(x) = K\left(\frac{\rho(x, x_i)}{h}\right)$  — веса объектов  $x_i$  относительно  $x$ ;

$K(r)$  — ядро, невозрастающее, ограниченное, гладкое;

$h$  — ширина окна сглаживания.

### Формула ядерного сглаживания Надарая–Ватсона:


$$a_h(x; X^\ell) = \frac{\sum_{i=1}^{\ell} y_i w_i(x)}{\sum_{i=1}^{\ell} w_i(x)} = \frac{\sum_{i=1}^{\ell} y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right)}.$$

## Проблема выбросов (эксперимент на синтетических данных)

$\ell = 100$ ,  $h = 1.0$ , гауссовское ядро  $K(r) = \exp(-2r^2)$

Две из 100 точек — выбросы с ординатами  $y_i = 40$  и  $-40$

Синяя кривая — выбросов нет



## Проблема выбросов и идея перевзвешивания объектов

**Проблема выбросов:** аномальные точки с большими случайными ошибками  $y_i$  сильно искажают функцию  $a_h(x)$

**Основная идея:**

Аномальность объекта — LOO-ошибка  $\varepsilon_i = |a_h(x_i; X^\ell \setminus x_i) - y_i|$ .

Чем больше  $\varepsilon_i$ , тем меньше должен быть вес  $w_i(x)$ .

Повторять в итерациях: обучение, перерасчёт ошибок и весов.

**Эвристика:**

домножить веса  $w_i(x)$  на коэффициенты  $\gamma_i = \tilde{K}(\varepsilon_i)$ ,  
где  $\tilde{K}(r)$  — ядро, вообще говоря, отличное от  $K(r)$ .

**Рекомендация:**

брать квадратичное ядро  $\tilde{K}(\varepsilon) = K_Q(\frac{\varepsilon}{6 \operatorname{med}\{\varepsilon_i\}})$ ,  
где  $\operatorname{med}\{\varepsilon_i\}$  — медиана вариационного ряда ошибок.

---

Gary W. Moran. Locally-Weighted-Regression Scatter-Plot Smoothing (LOWESS):  
a graphical exploratory data analysis technique. 1984

## Алгоритм LOWESS (LOcally WEighted Scatter plot Smoothing)

**Вход:**  $X^\ell$  — обучающая выборка;

**Выход:** коэффициенты  $\gamma_i$ ,  $i = 1, \dots, \ell$ ;

инициализация:  $\gamma_i := 1$ ,  $i = 1, \dots, \ell$ ;

**повторять**

оценки скользящего контроля в каждом объекте:

$$a_i := a_h(x_i; X^\ell \setminus \{x_i\}) = \frac{\sum_{j=1, j \neq i}^{\ell} y_j \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}{\sum_{j=1, j \neq i}^{\ell} \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}, \quad i = 1, \dots, \ell;$$

$$\gamma_i := \tilde{K}(|a_i - y_i|), \quad i = 1, \dots, \ell;$$

**пока** коэффициенты  $\gamma_i$  не стабилизируются;

---


Gary W. Moran. Locally-Weighted-Regression Scatter-Plot Smoothing (LOWESS): a graphical exploratory data analysis technique. 1984

## Пример работы LOWESS на синтетических данных

$\ell = 100$ ,  $h = 1.0$ , гауссовское ядро  $K(r) = \exp(-2r^2)$

Две из 100 точек — выбросы с ординатами  $y_i = 40$  и  $-40$

В данном случае LOWESS сходится за несколько итераций:



## Выявление новизны (novelty detection) и другие задачи

Аномальность объекта (anomaly/novelty/surprise score) — это значение функции потерь  $\mathcal{L}(a(x_i), y_i)$  на данном объекте

### Варианты оценивания аномальности:

- аномальность оценивается для объекта обучающей выборки (outlier) или для нового объекта (novelty)
- потеря зависит от  $y_i$  (supervised) или нет (unsupervised)
- при оценивании аномальности обучающего объекта он исключается из выборки ( $a(x_i; X^\ell \setminus x_i)$ ) или нет ( $a(x_i; X^\ell)$ )
- функция потерь та же, что в критерии обучения или нет

### Варианты использования оценок аномальности:

- жёсткое удаление аномальных объектов из выборки
- мягкое перевзвешивание весов объектов

---

*M. Salehi et al.* A unified survey on anomaly, novelty, open-set, and out-of-distribution detection: solutions and future challenges. 2021.

## Оптимизационные задачи машинного обучения

Постановки задач регрессии, классификации, кластеризации, восстановления плотности, снижения размерности и других отличаются функциями потерь  $\mathcal{L}_i(\alpha)$  и регуляризацией  $\tau R(\alpha)$ :

$$Q(\alpha) = \sum_{i=1}^{\ell} w_i \mathcal{L}_i(\alpha) + \tau R(\alpha) \rightarrow \min_{\alpha}$$

**Проблема:** выбросы могут исказить  $\mathcal{L}_i(\alpha)$  и критерий  $Q(\alpha)$

**Идея:** уменьшать веса  $w_i$  выбросов с большими  $\mathcal{L}_i(\alpha)$

введением функции медленного роста  $\mu(\mathcal{L})$ :

$$Q(\alpha) = \sum_{i=1}^{\ell} \mu(\mathcal{L}_i(\alpha)) + \tau R(\alpha) \rightarrow \min_{\alpha}$$

$$\nabla Q(\alpha) = \sum_{i=1}^{\ell} \underbrace{\mu'(\mathcal{L}_i(\alpha))}_{w_i} \nabla \mathcal{L}_i(\alpha) + \tau \nabla R(\alpha) = 0$$

## Итерационное взвешивание (Iterative Reweighting Scheme, IRS)

Пусть  $\mu(r)$  — функция медленного роста:

$\mu(r) \geq 0$ ,  $\mu'(r) \geq 0$ ,  $\mu'(r)$  убывает,  $\mu'(r) \rightarrow 0$  при  $r \rightarrow +\infty$

**Вход:**  $\mathcal{L}_i(\alpha)$  — функции потерь на обучающей выборке;

**Выход:** параметры модели  $\alpha$ , веса объектов  $w_i$ ;

инициализация:  $w_i := \frac{1}{\ell}$ ,  $i = 1, \dots, \ell$ ;

**повторять**

$$\left| \begin{array}{l} \alpha := \arg \min_{\alpha} \sum_{i=1}^{\ell} w_i \mathcal{L}_i(\alpha) + \tau R(\alpha); \\ w_i := \text{norm}_i(\mu'(\mathcal{L}_i(\alpha))), \quad i = 1, \dots, \ell; \end{array} \right.$$

**пока** веса  $w_i$  не стабилизируются;

где  $\text{norm}_i(v_i) = \frac{v_i}{\sum_j v_j}$  — операция нормирования вектора.

**Недостаток:** всё плохо, когда выбросы большие или их много



## Итерационное взвешивание наименьших квадратов

(Iteratively Reweighted Least Squares, IRLS)

Робастная регрессия:  $\mathcal{L}_i(\alpha) = |f(x_i, \alpha) - y_i|$

**Вход:**  $(x_i, y_i)_{i=1}^{\ell}$  — обучающая выборка;

**Выход:** параметры модели  $\alpha$ , веса объектов  $w_i$ ;

инициализация:  $w_i := \frac{1}{\ell}$ ,  $i = 1, \dots, \ell$ ;

**повторять**

$$\alpha := \arg \min_{\alpha} \sum_{i=1}^{\ell} w_i \underbrace{(f(x_i, \alpha) - y_i)^2}_{\mathcal{L}_i^2(\alpha)} + \tau R(\alpha);$$

$$w_i := \text{norm}_i \frac{\mu'(\mathcal{L}_i(\alpha))}{\mathcal{L}_i(\alpha)}, \quad i = 1, \dots, \ell;$$

**пока** веса  $w_i$  не стабилизируются;

**Недостаток:** всё плохо, когда выбросы большие или их много

## Функции потерь для робастной регрессии

Потеря  $\mathcal{L}_i(\alpha) = \mu(r)$  — функция  $\mu$  от ошибки  $r = f(x_i, \alpha) - y_i$   
Квадратичная функция потерь  $\mu(r) = r^2$  — не робастная.


Робастные функции потерь  $\mu(r)$ , с параметром  $c$ :

- $\max(0, |r| - c)$  — кусочно-линейная (SVM-regression)
- $c(1 - \exp(-\frac{r^2}{2c}))$  — Мешалкина
- $\begin{cases} \frac{1}{2c}r^2, & |r| < c \\ |r| - \frac{c}{2}, & |r| \geq c \end{cases}$  — Хьюбера
- $\begin{cases} \frac{c^2}{6}(1 - (1 - \frac{r}{c})^2)^3, & |r| < c \\ \frac{c^2}{6}, & |r| \geq c \end{cases}$  — Тьюки
- $\begin{cases} (1 - \cos \frac{\pi r}{c}), & |r| < c \\ 2c, & |r| \geq c \end{cases}$  — Эндрю


## Функции потерь для робастной регрессии

Семейство функций потерь Баррона с параметром  $\alpha$ :

$$\mu(r) = \frac{|\alpha - 2|}{\alpha} \left( \left( \frac{r^2}{|\alpha - 2|} + 1 \right)^{\alpha/2} - 1 \right)$$

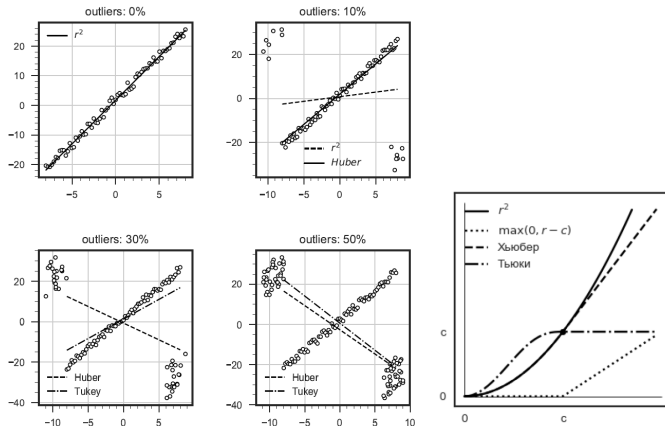


другие примеры робастных  $\mu(r)$



Jonathan T. Barron. A General and Adaptive Robust Loss Function. 2019.

## Пример. Робастная регрессия



**Недостаток:** всё плохо, когда выбросы большие или их много

З.М.Шибзухов. Методы машинного обучения на основе минимизации  
сглаженных оценок средних, нечувствительных к выбросам. ММРО-2019.

## Робастные (устойчивые к выбросам) способы усреднения

*Среднее арифметическое* (неустойчивое к большим выбросам):

$$\frac{1}{\ell} \sum_{i=1}^{\ell} z_i = \arg \min_u \sum_{i=1}^{\ell} (z_i - u)^2$$

Робастные (устойчивые) способы усреднения, определяемые через *вариационный ряд*  $z^{(1)} \leq \dots \leq z^{(\ell)}$  значений  $z_1, \dots, z_{\ell}$ :

- медиана  $\frac{1}{2} (z^{(\lfloor \frac{\ell+1}{2} \rfloor)} + z^{(\lceil \frac{\ell+1}{2} \rceil)}) = \arg \min_u \sum_{i=1}^{\ell} |z_i - u|$
- $\gamma$ -квантиль  $z^{(\lfloor \gamma \ell \rfloor)} = \arg \min_u \sum_{i=1}^{\ell} |z_i - u| \cdot \begin{cases} \gamma, & z_i \geq u \\ 1-\gamma, & z_i < u \end{cases}$
- цензурированное среднее  $\frac{1}{\ell} \sum_{i=1}^{\ell} \min(z_i, z^{(m)})$

**Недостаток:** эти функции усреднения недифференцируемы

## Общий вид и свойства агрегирующих функций

Идея 1: среднее заменить одномерной минимизацией по  $u$

Идея 2: затем модуль заменить его гладкой аппроксимацией

$$Q(\alpha) = M(\underbrace{\mathcal{L}_1(\alpha)}_{z_1}, \dots, \underbrace{\mathcal{L}_\ell(\alpha)}_{z_\ell}) = \arg \min_u \sum_{i=1}^{\ell} d(z_i - u)$$

Свойства функции несходства (dissimilarity function)  $d(r)$ :

- строго выпуклая,  $d(r) \geq 0$ ,  $d(0) = 0$

Свойства агрегирующей функции  $M(z_1, \dots, z_\ell)$ :

- $M(z_1) = z_1$
- монотонность:  $z_i \leq z'_i \rightarrow M(z_1, \dots, z_\ell) \leq M(z'_1, \dots, z'_\ell)$
- симметричность:  $M(z_1, \dots, z_\ell) = M(z_{\pi(1)}, \dots, z_{\pi(\ell)})$  для  $\forall \pi$
- $\min(z_1, \dots, z_\ell) \leq M(z_1, \dots, z_\ell) \leq \max(z_1, \dots, z_\ell)$



## Примеры сглаженных функций несходства

Сглаженный модуль (для аппроксимации медианы):

$$d_\varepsilon(r) = \sqrt{\varepsilon^2 + r^2} - \varepsilon \xrightarrow{\varepsilon \rightarrow 0} |r|$$

Сглаженный несимметричный модуль (для  $\gamma$ -квантили):

$$d_{\gamma\varepsilon}(r) = \begin{cases} 2\gamma d_\varepsilon(r), & r \geq 0 \\ 2(1-\gamma)d_\varepsilon(r), & r < 0 \end{cases} \xrightarrow{\varepsilon \rightarrow 0} |r|_\gamma = \begin{cases} 2\gamma|r|, & r \geq 0 \\ 2(1-\gamma)|r|, & r < 0 \end{cases}$$




## Ещё пример: сглаженное цензурированное среднее

Воспользуемся тождеством  $\min(z_i, u) = \frac{1}{2}(z_i + u) - \frac{1}{2}|z_i - u|$

$$M(z_1, \dots, z_\ell) = \frac{1}{2\ell} \sum_{i=1}^{\ell} z_i + \mathbf{z}_{\gamma\epsilon} - d_\epsilon(z_i - \mathbf{z}_{\gamma\epsilon}) \xrightarrow{\epsilon \rightarrow 0} \frac{1}{\ell} \sum_{i=1}^{\ell} \min(z_i, \mathbf{z}^{(m)})$$

$$\mathbf{z}_{\gamma\epsilon} = \arg \min_u \sum_{i=1}^{\ell} d_{\gamma\epsilon}(z_i - u) \xrightarrow{\epsilon \rightarrow 0} \mathbf{z}^{(m)}, \quad m = \gamma\ell$$





## Итерационное взвешивание для агрегирующей функции

Обобщённая минимизация эмпирического риска (ERM):

$$Q(\alpha) = M(\mathcal{L}_1(\alpha), \dots, \mathcal{L}_\ell(\alpha)) + \tau R(\alpha) \rightarrow \min_{\alpha}$$

$$\nabla Q(\alpha) = \sum_{i=1}^{\ell} \underbrace{\frac{\partial M}{\partial \mathcal{L}_i}(\mathcal{L}_1(\alpha), \dots, \mathcal{L}_\ell(\alpha))}_{w_i} \nabla \mathcal{L}_i(\alpha) + \tau \nabla R(\alpha) = 0$$

Алгоритм итерационного взвешивания (IR-ERM):

**повторять**

$$\left| \begin{array}{l} \alpha := \arg \min_{\alpha} \sum_{i=1}^{\ell} w_i \mathcal{L}_i(\alpha) + \tau R(\alpha); \\ w_i := \frac{\partial M}{\partial \mathcal{L}_i}(\mathcal{L}_1(\alpha), \dots, \mathcal{L}_\ell(\alpha)), \quad i = 1, \dots, \ell; \end{array} \right.$$

**пока** веса  $w_i$  не стабилизируются;

Теперь разберёмся, как вычислять производные  $\frac{\partial M}{\partial z_i}(z_1, \dots, z_\ell)$

## Вычисление частных производных $\frac{\partial M}{\partial z_k}$

Запишем необходимые условия экстремума по  $u \equiv M$

$$M(z_1, \dots, z_\ell) = \arg \min_u \sum_{i=1}^{\ell} d(z_i - u) \quad (*)$$

в виде уравнения  $\sum_{i=1}^{\ell} d'(z_i - M) = 0$  относительно  $M$ ,  
продифференцируем его по  $z_k$  и выразим отсюда  $\frac{\partial M}{\partial z_k}$ :

$$\begin{aligned} \sum_{i=1}^{\ell} d''(z_i - M) \frac{\partial}{\partial z_k} (z_i - M) &= 0 \\ d''(z_k - M) &= \frac{\partial M}{\partial z_k} \sum_{i=1}^{\ell} d''(z_i - M) \\ \frac{\partial M}{\partial z_k} &= \frac{d''(z_k - M)}{\sum_{i=1}^{\ell} d''(z_i - M)} = \text{norm}_k d''(z_k - M) \end{aligned}$$

Осталось разобраться, как вычислять  $u \equiv M$  в задаче  $(*)$

## Одномерная задача оптимизации по $M$

Чтобы решать уравнение  $\sum_{i=1}^{\ell} d'(z_i - M) = 0$  относительно  $M$  методом простой итерации, представим его в виде  $M = f(M)$ :

$$\sum_{i=1}^{\ell} \frac{d'(z_i - M)}{z_i - M} (z_i - M) = 0$$

$$\sum_{i=1}^{\ell} z_i \frac{d'(z_i - M)}{z_i - M} = M \sum_{i=1}^{\ell} \frac{d'(z_i - M)}{z_i - M}$$

$$M = \frac{\sum_{i=1}^{\ell} z_i \varphi(z_i - M)}{\sum_{i=1}^{\ell} \varphi(z_i - M)} = \sum_{i=1}^{\ell} z_i \text{norm}_i \varphi(z_i - M), \quad \text{где } \varphi(r) = \frac{d'(r)}{r}$$

Интересно, что  $M$  — средневзвешенное значений  $\{z_i\}$ .

## Достаточное условие сходимости метода простой итерации

Процесс  $M_{t+1} = f(M_t)$  сходится, если  $|f'(M)| < 1$   
в окрестности неподвижной точки  $M = f(M)$ .

$$\left| \frac{\partial}{\partial M} \frac{\sum_i z_i \varphi(z_i - M)}{\sum_i \varphi(z_i - M)} \right| < 1$$

После взятия производной по  $M$ :

$$\frac{|\sum_i (z_i - M) \varphi'(z_i - M)|}{|\sum_i \varphi(z_i - M)|} < 1$$

Данное условие нетрудно проверяется для каждой конкретной функции  $d(r)$ , и для большинства полезных  $d$  оно выполнено.

---

*Beliakov G., Sola H., Calvo T.* A practical guide to averaging functions. 2016.

З. М. Шибзухов. Минимизации робастных оценок сумм параметризованных функций. 2019.

## Собираем всё воедино: алгоритм IR-ERM

**Вход:**  $\mathcal{L}_i(\alpha)$  — функции потерь на обучающей выборке;

**Выход:** параметры модели  $\alpha$ , веса объектов  $w_i$ ;

инициализация  $w_i := \frac{1}{\ell}$ ,  $i = 1, \dots, \ell$ ;

**повторять**

$$\alpha := \arg \min_{\alpha} \sum_{i=1}^{\ell} w_i \mathcal{L}_i(\alpha) + \tau R(\alpha);$$

$$z_i := \mathcal{L}_i(\alpha); \text{ инициализация } M := \sum_{i=1}^{\ell} w_i z_i;$$

**повторять**

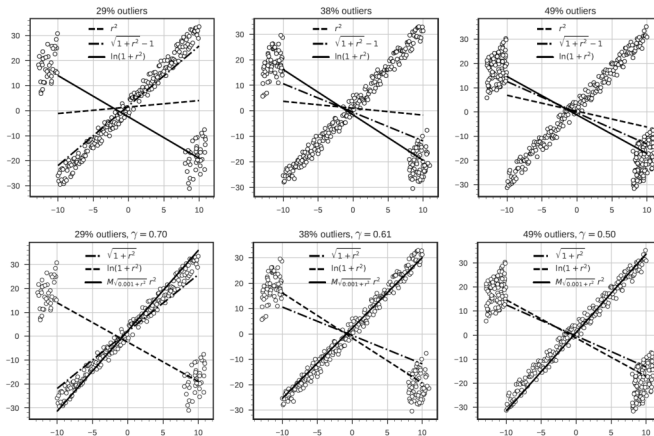
$$M = \sum_{i=1}^{\ell} z_i \operatorname{norm}_i \varphi(z_i - M), \text{ где } \varphi(r) = \frac{d'(r)}{r};$$

**пока** значение  $M$  не сойдётся;

$$w_i := \operatorname{norm}_i d''(z_i - M), \quad i = 1, \dots, \ell;$$

**пока** веса  $w_i$  не стабилизируются;

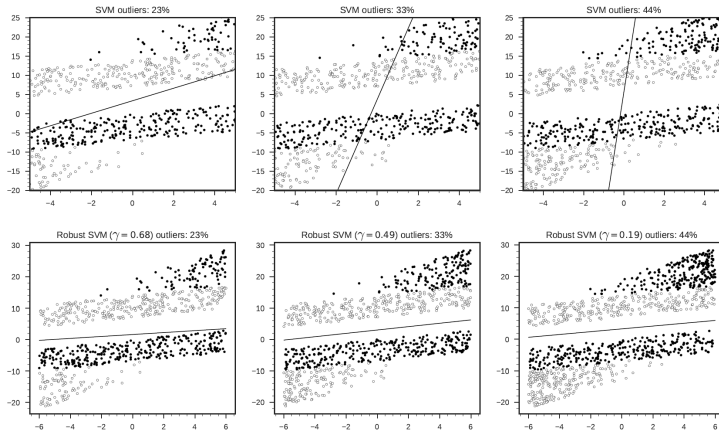
## Пример 1. Робастная регрессия (линейная)



Агрегирующая функция справляется даже с 49% выбросов

З.М.Шибзухов. Методы машинного обучения на основе минимизации  
сглаженных оценок средних, нечувствительных к выбросам. ММРО-2019.

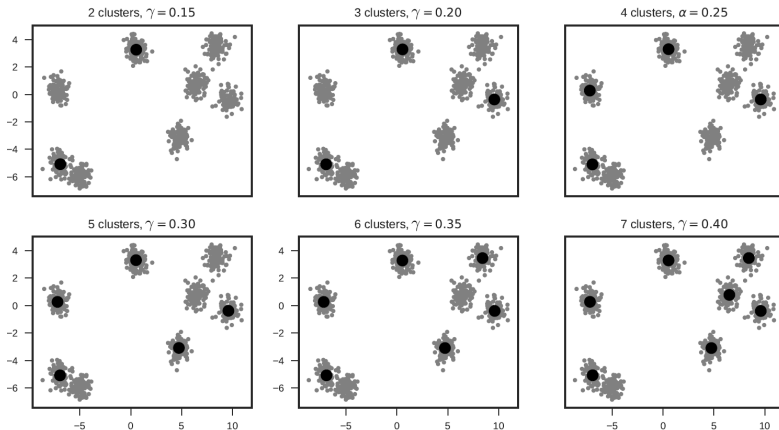
## Пример 2. Робастная классификация (SVM)



Агрегирующая функция справляется даже с 44% выбросов

З.М.Шибзухов. Методы машинного обучения на основе минимизации  
сглаженных оценок средних, нечувствительных к выбросам. ММРО-2019.

## Пример 3. Робастная кластеризация



Если в данных смешано несколько зависимостей, то вместо компромиссного «натягивания» одной модели на все данные *робастные методы* моделируют основную, игнорируя остальные




## Одноклассовый SVM (one-class SVM, OSVM)

**Дано:** обучающая выборка  $\{x_i \in \mathbb{R}^n: i = 1, \dots, \ell\}$

**Найти:** центр  $c \in \mathbb{R}^n$  и радиус  $r$  шара, охватывающего всю выборку кроме аномальных объектов-выбросов

**Критерий:** минимизация радиуса шара и суммы штрафов за выход из шара:

$$\nu r^2 + \sum_{i=1}^{\ell} \mathcal{L}(\underbrace{r^2 - \|x_i - c\|^2}_{\zeta_i = \text{margin}(c, r)}) \rightarrow \min_{c, r}$$



При  $\mathcal{L}(\zeta) = (-\zeta)_+$  свойства решения аналогичны SVM:

- Выпуклая задача квадратичного программирования
- Решение *разрежено* — зависит только от *опорных объектов*
- Обобщение на нелинейные модели:  $\langle x_i, x_j \rangle \rightarrow K(x_i, x_j)$

## Частный случай SSL: PU-learning (Positive and Unlabeled)

Примеры задач, когда известны объекты только одного класса:

- обнаружение мошеннических транзакций
- рекомендательные системы, персонализация рекламы
- автоматическое пополнение базы знаний фактами

Модель двухклассовой классификации  $a(x_i, w)$ .

Неразмеченные трактуются как негативные с весом  $C_- \ll C_+$ :

$$\sum_{i=1}^k \frac{C_+}{k} \mathcal{L}(a(x_i, w), +1) + \sum_{i=k+1}^{\ell} \frac{C_-}{\ell-k} \mathcal{L}(a(x_i, w), -1) + \tau R(w) \rightarrow \min_w$$


Один из успешных методов — Biased SVM.

---

*Gang Li.* A Survey on Positive and Unlabelled Learning. 2013.

*J.Bekker, J.Davis.* Learning From Positive and Unlabeled Data: A Survey. 2020.

## Задачи классификации с нефиксированным набором классов



- 1 Обычная многоклассовая классификация
- 2 Дообучение модели на каждом новом классе
- 3 Детектирование объектов одного класса против остальных (One-Class Classification)
- 4 Распознавание с открытым набором классов (Open-Set Recognition → Open-World Recognition)

- Природа аномальности объектов:
  - помехи (ошибки, шум, грязь) в исходных данных,
  - модель плохо описывает примеси посторонних явлений,
  - регулярно появляется что-то принципиально новое.
- Простой способ отсева наиболее грубых выбросов — исключать объекты с наибольшими значениями потерь.
- Редкий для ML случай: минимизируется не сумма потерь  $\mathcal{L}_1 + \dots + \mathcal{L}_\ell$ , а обобщённое среднее  $M(\mathcal{L}_1, \dots, \mathcal{L}_\ell)$ .
- Природа аномальности классов:
  - невозможность собрать обучающие объекты класса,
  - динамическое увеличение числа классов
- Не существует идеального способа определения аномалий. Явно или неявно предполагается «модель аномалии».

---

*З.М.Шибзухов.* Минимизации робастных оценок сумм параметризованных функций. 2019.

*M.Salehi et al.* A unified survey on anomaly, novelty, open-set, and out-of-distribution detection: solutions and future challenges. 2021.